

Memorial Descritivo — Mineração de Dados (OmniStore)

I. Seleção

Para montar a base final da OmniStore, o processo iniciou-se com o cruzamento das tabelas de "Acessos e Compras" com os "Detalhes dos Pedidos", utilizando a chave **ID_Sessao** para garantir a correlação correta entre a navegação e a efetivação da compra. Na sequência, este resultado foi integrado ao cadastro de clientes utilizando o **Nome** como chave de ligação.

O maior desafio desta etapa foi manter a integridade referencial dos dados. Para isso, optamos deliberadamente pela utilização do **Left Join**. A escolha deste método foi fundamental, pois se utilizássemos outro tipo de junção, os clientes que apenas visitaram o site sem realizar compras seriam excluídos do sistema. Manter esses registros é vital, uma vez que a ausência dessas informações distorceria o cálculo da taxa de conversão e prejudicaria o treinamento do modelo de inteligência artificial.

II. Pré-processamento

As planilhas originais apresentaram desafios de formatação que exigiram uma limpeza rigorosa antes da integração. Primeiramente, detectamos colunas aglutinadas em uma única string de texto, o que impossibilitava a análise direta. Para solucionar isso, desenvolvemos uma função específica para separar os dados por vírgulas e utilizamos o método **.strip()** para eliminar espaços em branco ocultos nas extremidades, garantindo a padronização das strings.

Adicionalmente, foi necessário converter os tipos de dados das colunas de Preço e Quantidade de texto para numérico, utilizando **pd.to_numeric(..., errors='coerce')**, permitindo assim que o Python executasse corretamente os cálculos financeiros.

Um passo crítico identificado durante a auditoria foi a presença de **65 registros duplicados na Base de Dados 1 (Cadastro de Clientes)** — de 105 linhas para apenas 40 clientes únicos. Sem o tratamento desse problema antes do merge, a operação de junção geraria um produto cartesiano, multiplicando cada cópia duplicada do cliente por todas as suas sessões e inflando a base de 159 para 486 linhas, corrompendo todos os KPIs subsequentes. A correção foi aplicar **drop_duplicates(subset='Nome', keep='first')** na base de clientes antes de qualquer cruzamento.

Por fim, aplicamos o método **.drop_duplicates()** também no resultado final do merge. Esta prática essencial de governança de dados evita a inflação artificial das vendas e do ticket médio, o que impediria decisões estratégicas baseadas em dados reais. A rotina de auditoria implementada confirmou a integridade da base após essas correções.

III. Transformação (Feature Engineering)

Para extrair inteligência real dos dados brutos, realizamos a engenharia de atributos, criando novas variáveis que respondem às necessidades estratégicas da empresa:

Total_Gasto: Criamos esta variável multiplicando o preço unitário pela quantidade vendida. Esta medida é superior a olhar apenas o preço unitário, pois reflete o valor financeiro real transacionado em cada carrinho.

Conversao: Definimos um indicador binário (1 para quem realizou pelo menos uma compra, 0 para quem apenas navegou). Esta variável foi o pilar principal para a avaliação do funil de vendas e para o treinamento do modelo preditivo.

Limpeza Dimensional: Após o processo de integração e cálculo das novas métricas, realizamos a exclusão da coluna de nome do cliente que se tornou redundante após o merge, garantindo uma estrutura de dados mais limpa e eficiente para o processamento.

IV. Conclusão (Resultados e Recomendações)

A análise da base de dados consolidada — após a correção das duplicatas — permitiu extrair os seguintes insights estratégicos para a gestão da OmniStore:

Ticket Médio: O valor médio das transações foi calculado em R\$ 157,83.

Desempenho por Categoria: A categoria de Eletrônicos destaca-se como a principal fonte de receita, totalizando R\$ 7.521,00.

Perfil Demográfico: O público de maior valor para a empresa possui uma idade média de 34 anos.

Comportamento de Consumo: Existe uma distinção clara por faixa etária: adultos concentram suas compras em eletrônicos, enquanto o público sênior foca em vestuário. Embora o público jovem apresente alto tráfego de navegação, a taxa de conversão deste grupo é baixa.

Melhores Clientes: Os três maiores compradores são Alexandre Souza (R\$ 1.710,00), Gustavo Mendes (R\$ 1.470,00) e Pedro Costa (R\$ 1.450,00), com idade média de 31 anos e preferência por Eletrônicos.

Casos Atípicos (Outliers): Identificamos 2 transações com valores superiores a R\$ 800,00, representando valores mais de quatro vezes maiores que o ticket médio.

Recomendações Estratégicas:

Marketing: Sugerimos o desenvolvimento de campanhas personalizadas para converter o alto volume de navegação do público jovem em vendas efetivas.

Governança Financeira: Alertamos a diretoria sobre a distorção causada pelos outliers de alto valor no cálculo da média. Recomendamos a utilização da mediana nos futuros relatórios financeiros para obter uma visão mais realista do comportamento de consumo da base de clientes.

V. Documentação do Modelo Preditivo

1. Refinamento do Target e Features

Definimos o alvo (target) como 1 para clientes que realizaram compra e 0 para aqueles que apenas navegaram, utilizando o campo **Compra_Finalizada** da base de dados. Esta abordagem é tecnicamente correta pois usa um campo de comportamento independente dos valores monetários, evitando o risco de **data leakage** (vazamento de dados). Caso utilizássemos o Ticket Médio como feature — como originalmente sugerido no roteiro — o modelo simplesmente aprenderia que quem tem gasto maior que zero comprou, atingindo 100% de acurácia de forma artificial e sem aprender padrão algum. A escolha garante que o modelo aprenda padrões comportamentais genuínos:

frequência de acesso, tempo desde a última interação e categoria de preferência.

2. Escolha do Algoritmo

Optamos pela **Árvore de Decisão (max_depth=4)** priorizando a explicabilidade. Diferente de modelos "caixa preta", a árvore nos permite mapear o caminho lógico que leva um cliente à conversão, entregando à diretoria regras de negócio claras e acionáveis. No contexto empresarial, a explicabilidade é tão importante quanto a precisão.

3. Performance e Matriz de Confusão

O modelo demonstrou alta capacidade preditiva, atingindo **92% de acurácia**. Analisando a Matriz de Confusão:

Zero Falsos Positivos: A IA não classificou nenhum visitante como comprador. Isso é estratégico pois protege o orçamento de marketing ao não direcionar campanhas para quem não possui real intenção de compra.

1 Falso Negativo: O modelo deixou passar 1 comprador real. Financeiramente, é muito mais seguro perder uma oportunidade passiva do que queimar o orçamento de marketing com o público errado.

É importante ressaltar que, devido ao volume reduzido da amostra (40 clientes), a acurácia pode apresentar variações entre execuções — um comportamento esperado em subconjuntos de teste pequenos. Esta transparência é fundamental para a governança de dados.

VI. Documentação Técnica das Funções Python Utilizadas

Para garantir a transparência e a reprodutibilidade do pipeline de dados, detalhamos abaixo as principais funções das bibliotecas pandas e scikit-learn aplicadas no projeto:

1. Funções de Extração e Pré-processamento

pd.read_excel(): Realiza a ingestão dos dados brutos das planilhas Excel para a memória do script.

str.split(',') e str.strip(): Aplicadas para corrigir a formatação das bases originais, separando textos aglutinados por vírgula e removendo espaços em branco ocultos.

pd.to_numeric(..., errors='coerce'): Converte as colunas de Preço e Quantidade de texto para tipo numérico, viabilizando os cálculos financeiros.

drop_duplicates(): Identifica e remove registros duplicados. Aplicada em dois momentos: na base de clientes antes do merge (corrigindo 65 duplicatas) e no resultado final do cruzamento.

2. Funções de Integração e Transformação

pd.merge(..., how='left'): Executa a junção relacional das bases de dados pelas chaves primárias e estrangeiras. O parâmetro how='left' foi fundamental para manter os clientes inativos na análise.

groupby(): Utilizada para a agregação de dados, permitindo tanto o cálculo dos KPIs da diretoria quanto a construção dos atributos RFM agrupando por cliente único.

3. Funções de Machine Learning (Modelagem Preditiva)

train_test_split(): Divide a base aleatoriamente em 70% para treino e 30% para teste, garantindo a avaliação do modelo com dados inéditos.

DecisionTreeClassifier(max_depth=4): Instancia o algoritmo de Árvore de Decisão com profundidade limitada a 4 níveis, evitando o overfitting e assegurando a interpretabilidade das regras de negócio.

confusion_matrix() e classification_report(): Avaliam as previsões da IA gerando, respectivamente, a contagem de falsos positivos/negativos e as métricas de Acurácia, Precisão e Recall.